

Análise de Perfis de Risco em Saúde Materna por Clusterização Não Supervisionada

Gabriel Stiegemeier¹, Guilherme Einloft¹

¹Universidade Federal de Santa Maria
Santa Maria, RS, Brasil

{gstiegemeier, geinloft}@inf.ufsm.br

1. Introdução

Neste projeto, aplicamos técnicas de aprendizado não supervisionado para explorar o **Maternal Health Risk Data Set**, um conjunto de dados público focado na saúde de gestantes. O dataset está disponível no UCI Machine Learning Repository e no Kaggle, e foi originalmente analisado no artigo de [?]. A ideia central é investigar o comportamento de algoritmos clássicos de clusterização diante de dados reais e fisiológicos.

1.1. Justificativa da Escolha do Dataset

Embora a especificação do trabalho prático liste como exemplos de domínio *Diabetes*, *Doença Cardiovascular ou Hipertensão*, o dataset **Maternal Health Risk** foi escolhido por ser **diretamente fundamentado nessas mesmas condições clínicas**. Das seis variáveis preditoras do dataset, três são marcadores centrais dessas patologias:

- **SystolicBP e DiastolicBP (Pressão Arterial Sistólica e Diastólica):** São os indicadores primários para diagnóstico de **hipertensão gestacional e pré-eclâmpsia**, condições hipertensivas que afetam 5–8% das gestações e representam uma das principais causas de mortalidade materna. Os limiares diagnósticos ($PA \geq 140/90$ mmHg) estão diretamente representados nos dados.
- **BS (Blood Sugar — Glicemia):** É o marcador fundamental para diagnóstico de **diabetes mellitus gestacional (DMG)**, condição que acomete 7–14% das gestações. Valores elevados de BS no dataset correspondem diretamente aos critérios diagnósticos de diabetes.

Portanto, apesar de o dataset ter como tema a saúde materna, **as variáveis utilizadas e os perfis de risco investigados são intrinsecamente ligados à hipertensão e ao diabetes** — duas das três condições explicitamente mencionadas na especificação. O clustering aplicado neste trabalho busca, na prática, identificar subgrupos de pacientes com perfis hipertensivos e/ou diabéticos.

Além disso, o dataset atende a todos os critérios técnicos exigidos: é real, possui mais de 1.000 instâncias e foi utilizado em artigo científico publicado.

1.2. Definição do Problema

Tese: Investigar se algoritmos de clustering não supervisionados conseguem agrupar naturalmente gestantes em perfis de risco (alto, médio, baixo) utilizando exclusivamente métricas fisiológicas — como pressão arterial, níveis de glicose, idade, temperatura corporal e frequência cardíaca — sem que o algoritmo tenha acesso ao diagnóstico prévio.

Essa investigação é relevante porque, caso os algoritmos consigam formar agrupamentos que correspondam aos níveis de risco previamente diagnosticados por especialistas, isso validaria a existência de **padrões fisiológicos naturais** que distinguem gestantes de alto, médio e baixo risco.

Hipóteses formais:

- **H1:** Os algoritmos de clusterização formarão agrupamentos que correspondem aos três níveis de risco originais (alto, médio e baixo), indicando que as métricas fisiológicas disponíveis são suficientes para estratificar gestantes.
- **H2:** O cluster de alto risco será o mais distinguível dos três, apresentando a maior pureza na correspondência com o rótulo original, dado que as condições de alto risco (hipertensão severa, diabetes descompensado) envolvem alterações fisiológicas mais pronunciadas.

1.3. Descrição do Dataset

O dataset é composto por **1.014 registros** coletados por meio de dispositivos IoT (Internet of Things) e sistemas hospitalares, contendo as variáveis apresentadas na Tabela 1.

Tabela 1. Descrição das Variáveis do Dataset

Variável	Tipo	Descrição
Age	int	Idade da gestante (anos)
SystolicBP	int	Pressão arterial sistólica (mmHg)
DiastolicBP	int	Pressão arterial diastólica (mmHg)
BS	float	Nível de glicose no sangue (mmol/L)
BodyTemp	float	Temperatura corporal (Fahrenheit)
HeartRate	int	Frequência cardíaca (bpm)
RiskLevel	string	Nível de risco: low risk, mid risk, high risk

A distribuição original dos rótulos é de 406 para Low Risk (40.0%), 336 para Mid Risk (33.1%) e 272 para High Risk (26.8%).

Nota: A coluna RiskLevel foi utilizada apenas na Análise Descritiva para contextualização e na etapa final de Interpretação para validação dos clusters. Ela foi removida antes de qualquer etapa de modelagem, respeitando o caráter não supervisionado dos algoritmos.

2. Análise Descritiva (EDA)

2.1. Análise Univariada

A Tabela 2 resume as estatísticas descritivas de todas as variáveis numéricas:

Tabela 2. Estatísticas Descritivas das Variáveis Numéricas								
Variável	Média	Mediana	Desvio Padrão	Mín	Q1	Q3	Máx	IQR
Age	29.87	26.0	13.47	10	19	39	70	20
SystolicBP	113.20	120.0	18.40	70	100	120	160	20
DiastolicBP	76.46	80.0	13.89	49	65	90	100	25
BS	8.73	7.5	3.29	6	6.9	8.0	19	1.1
BodyTemp	98.67	98.0	1.37	98	98	98	103	0
HeartRate	74.30	76.0	8.09	7	70	80	90	10

Observações-chave da análise univariada:

- **Age:** Distribuição assimétrica à direita (média > mediana), com amplitude de 10 a 70 anos, indicando grande diversidade etária no dataset.
- **SystolicBP e DiastolicBP:** Apresentam correlação forte entre si (detalhado na análise bivariada). A sistólica concentra-se em torno de 120 mmHg.
- **BS (Glicose):** Fortemente assimétrica à direita, com mediana 7.5 e média 8.73, indicando que a maioria das gestantes apresenta níveis normais, mas há um sub-grupo com glicose elevada (até 19 mmol/L).
- **BodyTemp:** Concentração extrema em 98.0 °F, com IQR = 0, indicando baixa variabilidade. Valores acima de 100 °F sugerem condições febris.
- **HeartRate:** Foram identificados **2 registros com HeartRate = 7 bpm**, valores fisiologicamente impossíveis que representam erros de digitação. Esses registros foram tratados na etapa de pré-processamento.

As Figuras 1 e 2 ilustram a distribuição das variáveis.




Figura 1. Distribuição das Variáveis — Histogramas




Figura 2. Detecção de Outliers — Boxplots

2.2. Análise Bivariada

As matrizes de correlação (Pearson e Spearman) revelaram as seguintes relações mais relevantes (Tabela 3):

Tabela 3. Principais Correlações Bivariadas

Par de Variáveis	Pearson	Spearman	Interpretação
SystolicBP × DiastolicBP	0.787	0.757	Correlação forte e positiva
Age × BS	0.473	0.320	Correlação moderada
Age × SystolicBP	0.416	0.485	Correlação moderada
BS × SystolicBP	0.425	0.262	Correlação moderada
BodyTemp × Age	-0.255	-0.305	Correlação fraca negativa
HeartRate × BS	0.143	0.129	Correlação negligenciável

Observações:

- A forte correlação entre **SystolicBP e DiastolicBP** ($r = 0.787$) era esperada clinicamente, pois ambas representam componentes da pressão arterial.
- A correlação moderada entre **Age e BS** ($r = 0.473$) sugere que gestantes mais velhas tendem a apresentar níveis glicêmicos mais elevados.
- **HeartRate** apresenta correlação fraca com todas as outras variáveis, sugerindo que a frequência cardíaca atua como variável relativamente independente.

A Figura 3 ilustra o relacionamento bivariado por nível de risco.

Análise Bivariada — Scatter Plots por Nível de Risco




Figura 3. Análise Bivariada — Scatter Plots por Nível de Risco

2.3. Análise Multivariada

A **Análise de Componentes Principais (PCA)** foi aplicada aos dados padronizados para visualização bidimensional e análise da estrutura de variância do dataset. O **Scree Plot** (Tabela 4 e Figura 4) mostra a contribuição individual e cumulativa de cada componente principal.

Tabela 4. Variância Explicada por Componente (PCA)

Componente	Variância Individual	Variância Cumulativa
PC1	43.5%	43.5%
PC2	19.1%	62.5%
PC3	14.0%	76.5%
PC4	11.8%	88.3%
PC5	8.2%	96.5%
PC6	3.5%	100.0%

A análise do Scree Plot revela que **duas componentes explicam 62.5% da variância total**, enquanto são necessárias **quatro componentes para atingir ~88%**. A escolha de 2 componentes para visualização é justificada pelo ponto de inflexão (cotovelo) observado entre PC2 e PC3.




Figura 4. Scree Plot — Variância Explicada por Componente

A projeção PCA colorida pelos rótulos originais (RiskLevel) na Figura 6 revela que os grupos de risco apresentam **sobreposição considerável** no espaço bidimensional, com pontos de *high risk* tendendo a se concentrar na região de valores positivos de PC1, enquanto *low risk* tende para valores negativos. Essa sobreposição sugere que a separação entre os níveis de risco não é trivial e representa um desafio real para os algoritmos de clusterização. As correlações multivariadas também podem ser verificadas na Figura 5.




Figura 5. Matrizes de Correlação — Pearson e Spearman




Figura 6. PCA — Visualização 2D dos Dados colorida por RiskLevel

3. Pré-processamento

3.1. Tratamento de Valores Faltantes

O dataset **não possui valores faltantes (NaN)** em nenhuma das colunas. Nenhum tratamento de imputação foi necessário.

3.2. Remoção de Outliers Extremos (Erros de Digitação)

Foram identificados **2 registros** com `HeartRate` = 7 bpm, um valor fisiologicamente impossível para seres humanos (a frequência cardíaca mínima viável em repouso é cerca de 40–50 bpm). Ambos os registros pertencem a uma gestante de 16 anos com as mesmas características (provavelmente o mesmo registro duplicado):

Tabela 5. Registros com Erro de Digitação Removidos

Age	SystolicBP	DiastolicBP	BS	BodyTemp	HeartRate	RiskLevel
16	120	75	7.9	98.0	7	low risk
16	120	75	7.9	98.0	7	low risk

Esses registros foram **removidos do dataset** por serem claramente erros de digitação (provavelmente o valor correto seria 70 ou 77 bpm). Restaram **1.012 registros** após a remoção.

3.3. Tratamento de Outliers via IQR

Para as demais variáveis, foi aplicado o método de **clipping baseado no Intervalo Inter-quartil (IQR)**, que limita os valores ao intervalo $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$. A Tabela 6 resume a aplicação:

Tabela 6. Limites de Clipping via IQR

Variável	Limite Inferior	Limite Superior	Outliers Tratados
Age	-11.00	69.00	1
SystolicBP	70.00	150.00	10
DiastolicBP	27.50	127.50	0
BS	5.25	9.65	210
BodyTemp	98.00	98.00	210
HeartRate	55.00	95.00	0

Decisões e justificativas:

- **BS (210 outliers):** A grande quantidade de outliers reflete a assimetria extrema da distribuição de glicose. Valores acima de 9.65 mmol/L foram clipados, não removidos, para preservar a informação de que essas gestantes tinham glicose elevada sem distorcer as distâncias euclidianas usadas pelos algoritmos.
- **BodyTemp (210 outliers):** Com $IQR = 0$ ($Q1 = Q3 = 98$), todos os valores acima de 98 são tecnicamente “outliers” pelo método IQR. O clipping padronizou esses valores, mas é importante notar que a variável perde variabilidade após o tratamento, tornando-se efetivamente constante. Após a padronização, o desvio padrão de BodyTemp aproxima-se de zero, o que significa que essa variável contribui minimamente para o clustering.
- O **clipping** foi preferido à remoção para não reduzir excessivamente o tamanho do dataset.

3.4. Remoção do Rótulo

A coluna `RiskLevel` foi removida do conjunto de dados **antes de qualquer etapa de modelagem**. Os rótulos foram salvos em uma variável separada para uso exclusivo na etapa de interpretação posterior.

3.5. Padronização

Foi aplicado o `StandardScaler` do pacote *scikit-learn* [?], que transforma cada variável para média 0 e desvio padrão 1. Essa padronização é essencial para algoritmos baseados em distância.

3.6. PCA para Visualização

Após o pré-processamento e padronização, o PCA foi recalculado sobre os dados tratados, resultando em: PC1 (47.4%) e PC2 (22.7%), totalizando 70.1% da variância explicada (uma melhoria em relação aos 62.5% pré-tratamento).

4. Modelagem

Três algoritmos de clusterização foram implementados. As métricas de avaliação [?] utilizadas foram:

- **Silhouette Score:** Mede a coesão intra-cluster e separação inter-cluster. Intervalo: $[-1, 1]$.

- **Davies-Bouldin Index (DBI):** Razão entre dispersão intra-cluster e distância inter-cluster. Valores menores indicam agrupamentos melhores. Intervalo: $[0, \infty)$.
- **Calinski-Harabasz Score (CHI):** Razão entre variância inter-cluster e intra-cluster. Valores maiores indicam clusters mais densos e separados.

4.1. K-Means

O K-Means foi testado com $K \in \{2, 3, 4, 5\}$ e métodos de inicialização k-means++ e random (Tabela 7).

Tabela 7. Resultados do K-Means

K	Init	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	k-means++	0.3123	1.3064	467.60
3	k-means++	0.3148	1.2216	484.40
4	k-means++	0.3110	1.3429	421.06
5	k-means++	0.2842	1.2604	381.86

Análise: O método do cotovelo (Figura 7) sugere um ponto de inflexão em $K = 3$. O Silhouette Score (Figura 8) atingiu seu máximo neste valor (0.3148). A inicialização k-means++ vs random não produziu diferenças significativas, indicando boa estabilidade.




Figura 7. Método do Cotovelo — K-Means




Figura 8. Silhouette Score por K — K-Means

4.2. Agglomerative Clustering

O modelo hierárquico foi testado com $n_clusters \in \{2, 3, 4, 5\}$ e métodos de linkage (Tabela 8).

Tabela 8. Resultados do Agglomerative Clustering (Top configurações)				
n_clusters	Linkage	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	ward	0.3399	1.1177	394.21
2	average	0.3380	1.1396	402.41
3	ward	0.2956	1.2849	447.63
4	average	0.3071	1.1002	351.93

Análise: O linkage *ward* obteve os melhores resultados. É notável que o melhor Silhouette (0.3399) ocorreu com **2 clusters**, sugerindo que a separação mais natural nos dados é binária (risco elevado vs. não-elevado). O dendrograma ilustra essa hierarquia (Figura 9).




Figura 9. Dendrograma — Agglomerative Clustering

4.3. DBSCAN

O DBSCAN foi testado com várias combinações de ϵ e $min_samples$ (Tabela 9).

Tabela 9. Resultados do DBSCAN (Amostra Selecionada)

eps	min_s	Clusters	Ruído	Silhouette	DBI	CHI
0.3	3	117	230	0.7864	0.2836	1308.31
0.3	15	5	886	0.8901	0.2041	5305.39
0.5	5	63	262	0.6159	0.5170	388.25
0.7	10	20	332	0.4204	0.6885	227.70
1.0	5	14	38	0.0315	0.8042	62.04

Seleção do melhor modelo: Configurações com Silhouette artificialmente altos classificavam até 87.5% dos dados como ruído (886 pontos em $\epsilon = 0.3$). Aplicando uma restrição de cobertura ($\leq 50\%$ de ruído), o "melhor" modelo seria $\epsilon = 0.3$, $min_samples = 3$, com 22.7% de ruído.

Análise crítica: Mesmo com a restrição, o DBSCAN gerou **117 microclusters**, impedindo qualquer interpretação clínica. O *K-Distance Plot* (Figura 10) confirma que o dataset não possui estrutura de densidade definida, tornando o DBSCAN inadequado para este cenário.




Figura 10. K-Distance Plot para escolha de eps

5. Avaliação Comparativa

5.1. Tabela Comparativa dos Melhores Modelos

A Tabela 10 resume a melhor configuração encontrada para cada algoritmo.

Tabela 10. Comparação dos Melhores Modelos por Algoritmo

Algoritmo	Melhor Configuração	Silhouette	DBI	CHI
K-Means	K=3, init=k-means++	0.3148	1.2216	484.40
Agglomerative	n_clusters=2, linkage=ward	0.3399	1.1177	394.21
DBSCAN	eps=0.3, min_samples=3	0.7864*	0.2836*	1308.31*

*Valores do DBSCAN elevados pela natureza do algoritmo (microclusters densos com exclusão de 22.7% dos dados como ruído). Não diretamente comparáveis com K-Means e Agglomerative, que classificam todos os pontos.

5.2. Discussão Comparativa

K-Means vs. Agglomerative: Os resultados de ambos os algoritmos são próximos em termos de Silhouette (0.31 vs. 0.34), o que é esperado dado que ambos utilizam distâncias euclidianas. O Agglomerative com 2 clusters obteve Silhouette ligeiramente superior, sugerindo que a separação binária (risco elevado vs. não-elevado) é mais nítida do que a ternária. No entanto, o K-Means com $K = 3$ apresentou melhor Calinski-Harabasz (484 vs. 394), indicando que, apesar de mais difusa, a separação em 3 grupos captura mais variância inter-cluster.

DBSCAN: A estrutura dos dados não apresenta clusters de densidade uniforme claramente separados por regiões de baixa densidade — premissa fundamental do DBSCAN. Os dados se distribuem de forma mais difusa, favorecendo algoritmos baseados em partição.

Conclusão da avaliação: Para fins práticos de estratificação de risco materno, o **K-Means com K=3** é o modelo mais adequado, pois (1) classifica todas as instâncias, (2) gera 3 clusters alinhados ao número real de níveis de risco, e (3) apresenta métricas competitivas.




Figura 11. Comparação de Métricas — Melhores Modelos por Algoritmo

6. Interpretação dos Clusters

6.1. K-Means (K=3) — Melhor modelo para interpretação

Após a clusterização, os rótulos originais (`RiskLevel`) foram reintroduzidos para avaliar a correspondência empírica (Tabela 11).

Tabela 11. Tabela de Contingência (Cluster $\times$ RiskLevel) — K-Means

Cluster	High Risk	Low Risk	Mid Risk	Total
0	157 (77.0%)	9 (4.4%)	38 (18.6%)	204
1	59 (18.8%)	160 (51.1%)	94 (30.0%)	313
2	56 (11.3%)	235 (47.5%)	204 (41.2%)	495
Total	272	404	336	1012

Tabela 12. Perfil Médio de Cada Cluster — K-Means

Cluster	Age	SystolicBP	DiastolicBP	BS	BodyTemp	HeartRate
0	45.07	130.39	89.83	9.50	98.0	77.13
1	21.81	90.33	60.96	7.48	98.0	75.99
2	28.76	120.34	80.76	7.13	98.0	72.34

Análise dos Clusters:

- Cluster 0 (n=204) — Alto Risco:** Capturou **77.0% de gestantes high risk**. Perfil: idade elevada (média 45 anos), pressão arterial sistólica alta (130 mmHg) e glicose elevada (9.5 mmol/L). O algoritmo identificou o subgrupo com precisão. O perfil é consistente com pré-eclâmpsia e diabetes gestacional, **confirmando a hipótese H2**.
- Cluster 1 (n=313) — Baixo Risco:** Concentra **51.1% de gestantes low risk**. Perfil: jovens (média 22 anos), pressão baixa (90/61 mmHg) e glicose normal (7.48 mmol/L). Contudo, contém 30% de mid risk.

- **Cluster 2 (n=495) — Perfil Misto:** Maior cluster, distribuição equilibrada entre low (47.5%) e mid (41.2%) risk. Isso revela que **low risk e mid risk são difíceis de separar**.




Figura 12. Clusters K-Means no espaço PCA




Figura 13. Distribuição de RiskLevel por Cluster — Heatmap

6.2. Síntese da Interpretação

Os resultados demonstram que:

1. O K-Means com $K = 3$ identifica com boa acurácia o grupo de alto risco (77% de pureza no Cluster 0), confirmando H2.
2. A separação entre low risk e mid risk é difícil, sugerindo que os critérios clínicos para diferenciar esses níveis envolvem mais do que as 6 métricas disponíveis. Logo, H1 é parcialmente refutada.
3. A estrutura natural dos dados aproxima-se de uma separação binária (alto risco vs. não-alto risco).

7. Conclusão

Este trabalho investigou se algoritmos de clusterização não supervisionada conseguem agrupar gestantes em perfis de risco utilizando exclusivamente métricas fisiológicas. Os três algoritmos testados — K-Means, Agglomerative Clustering e DBSCAN — revelaram padrões importantes.

O **K-Means com $K=3$** demonstrou ser o mais adequado para a tarefa, isolando um cluster de alto risco com **77% de pureza**, com perfil clínico coerente. Esse resultado valida parcialmente a tese de que existem padrões fisiológicos naturais que distinguem os níveis de risco, **confirmando a hipótese H2** (alto risco é o mais distinguível) e **parcialmente confirmando H1** (três agrupamentos são formados, mas com sobreposição).

A **principal limitação** observada é a dificuldade de separar gestantes de baixo e médio risco, cujas métricas fisiológicas apresentam sobreposição considerável. O **DBSCAN** mostrou-se inadequado para dados com distribuição contínua, enquanto o **Agglomerative Clustering** confirmou que a separação binária é a fronteira mais nítida.

Em resumo, os algoritmos **são eficazes para identificar o perfil de alto risco materno**, mas insuficientes para uma estratificação completa em três níveis sem informações adicionais.